NOWOCZESNE METODY PRZECHOWYWANIA DANYCH: OD RELACYJNYCH HURTOWNI DO DATA LAKEHOUSE

AGENDA

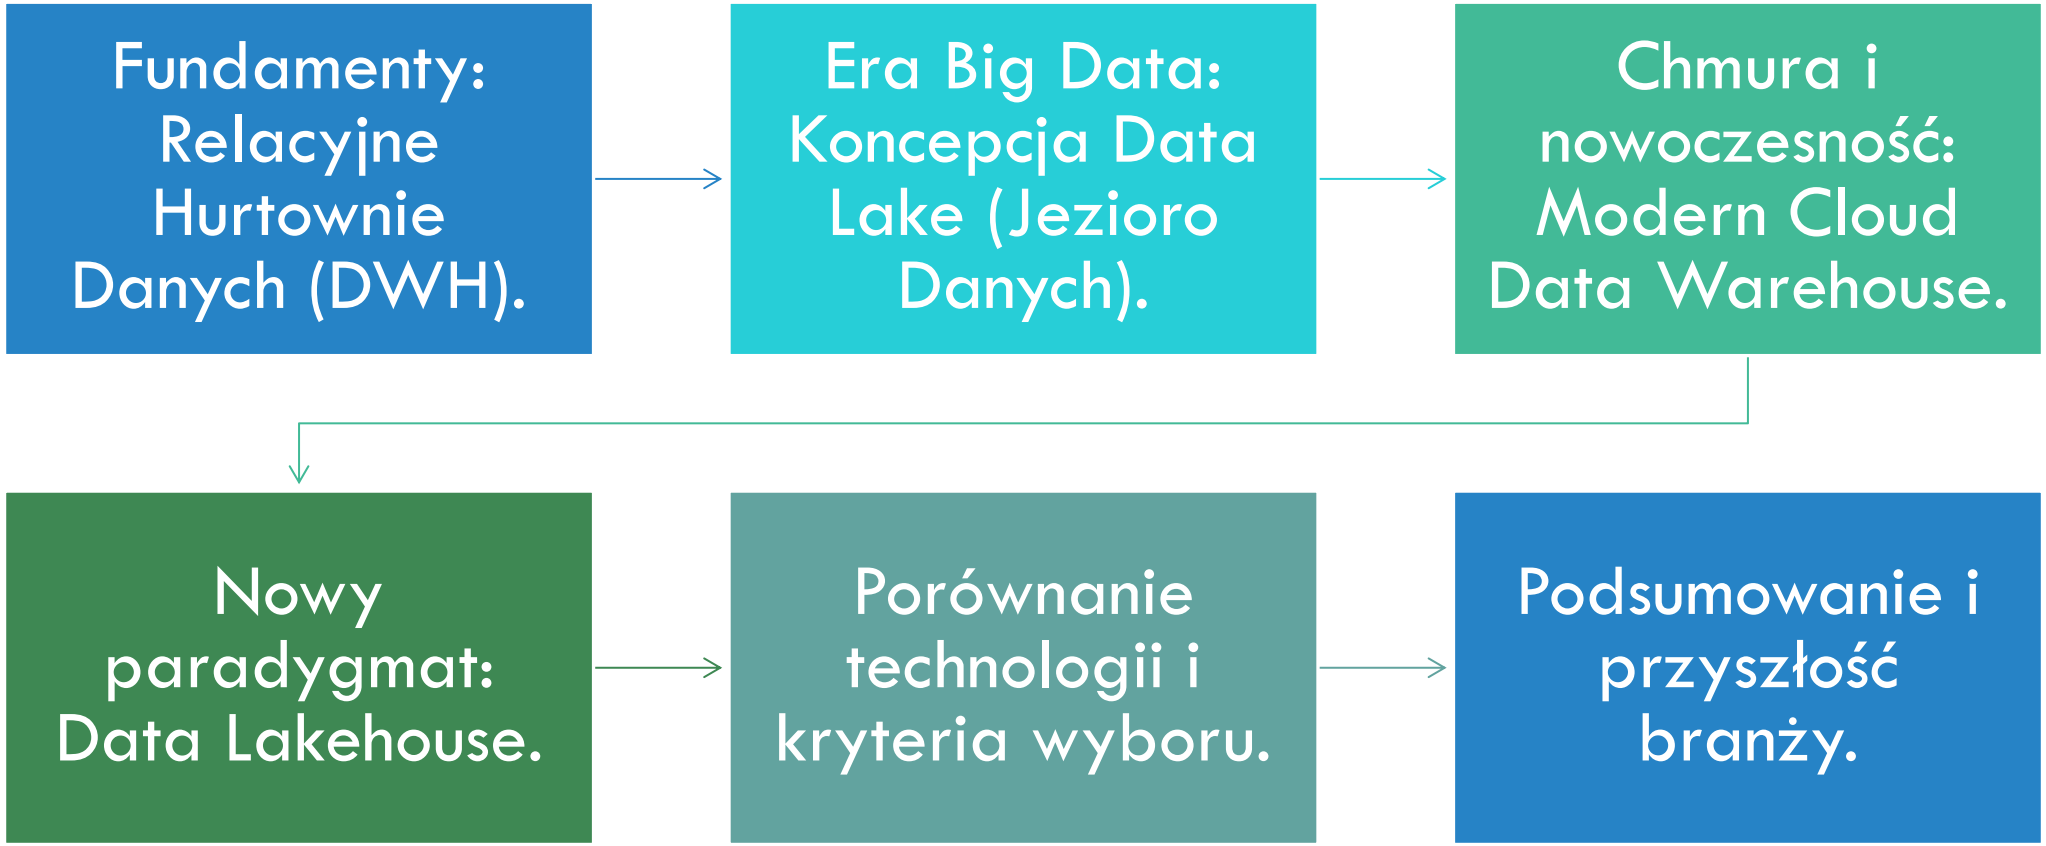
Fundamenty: Relacyjne Hurtownie Danych (DWH).
Era Big Data: Koncepcja Data Lake (Jezioro Danych).
Chmura i nowoczesność: Modern Cloud Data Warehouse.
Nowy paradygmat: Data Lakehouse.
Porównanie technologii i kryteria wyboru.
Podsumowanie i przyszłość branży.

WSTĘP – DLACZEGO SPOSÓB PRZECHOWYWANIA MA ZNACZENIE?

- **Dane jako "paliwo" gospodarki:** To nie tylko przechowywanie, ale możliwość szybkiej analizy decyduje o przewadze rynkowej.
- **Wyzwania współczesności:**
- Ogromny wolumen (Volume).
- Różnorodność formatów (Variety – wideo, logi, JSON).
- Prędkość przetwarzania (Velocity).
- **Cel prezentacji:** Zrozumienie, jak architektura ewoluowała, by sprostać tym wymaganiom.

EWOLUCJA DANYCH NA OSI CZASU

Lata 80./90.: Pliki płaskie i wczesne bazy relacyjne.

Lata 2000.: Rozkwit korporacyjnych hurtowni danych (EDW).

Lata 2010.: Rewolucja Hadoop i narodziny Data Lake.

Lata 2020.+: Dominacja chmury i powstanie architektury Lakehouse.

PROBLEM SILOSÓW INFORMACYJNYCH

Definicja: Sytuacja, w której dane są odizolowane w różnych działach firmy.

Skutki:

Niespójne wyniki raportów.

Wielokrotne płacenie za przechowywanie tych samych informacji.

Trudność w uzyskaniu pełnego obrazu klienta

Rozwiązanie: Jednolita architektura przechowywania danych.

Starsze aplikacje + bazy danych = chaos

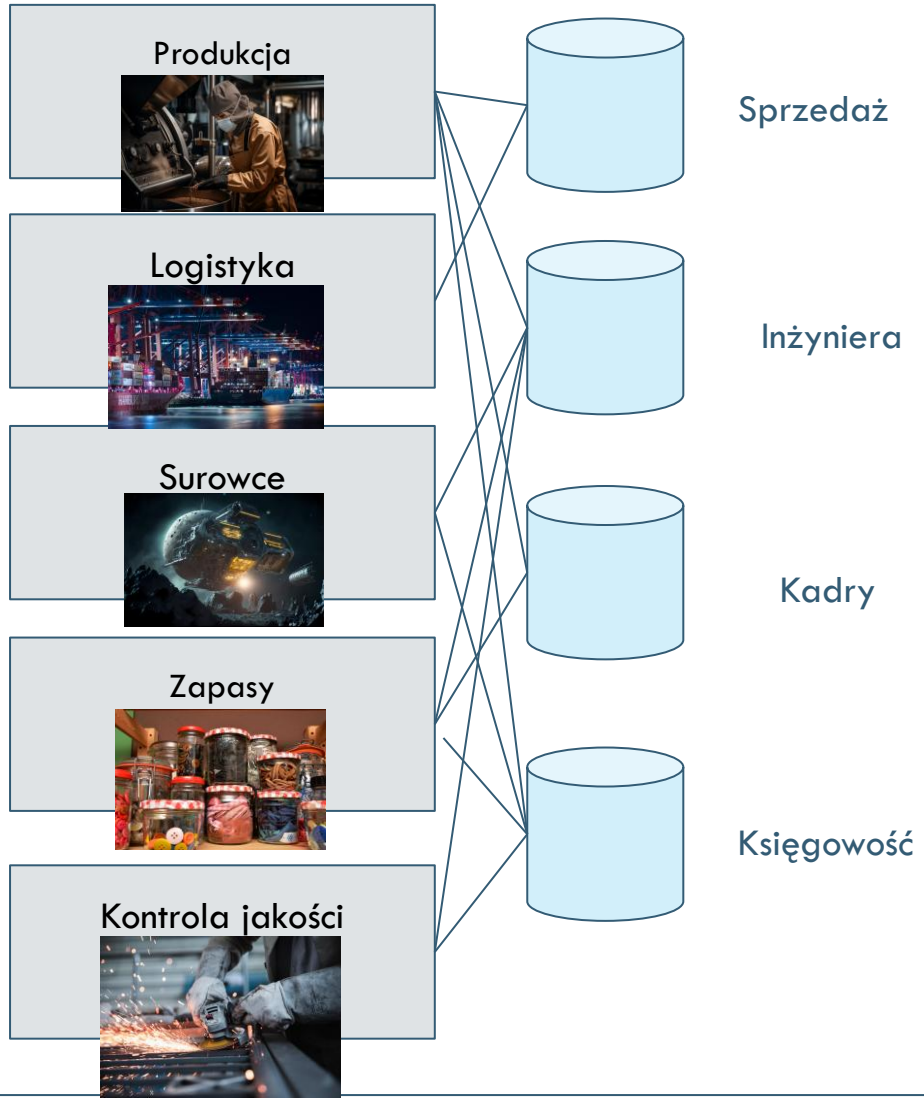

Korporacyjna hurtownia danych = porządek

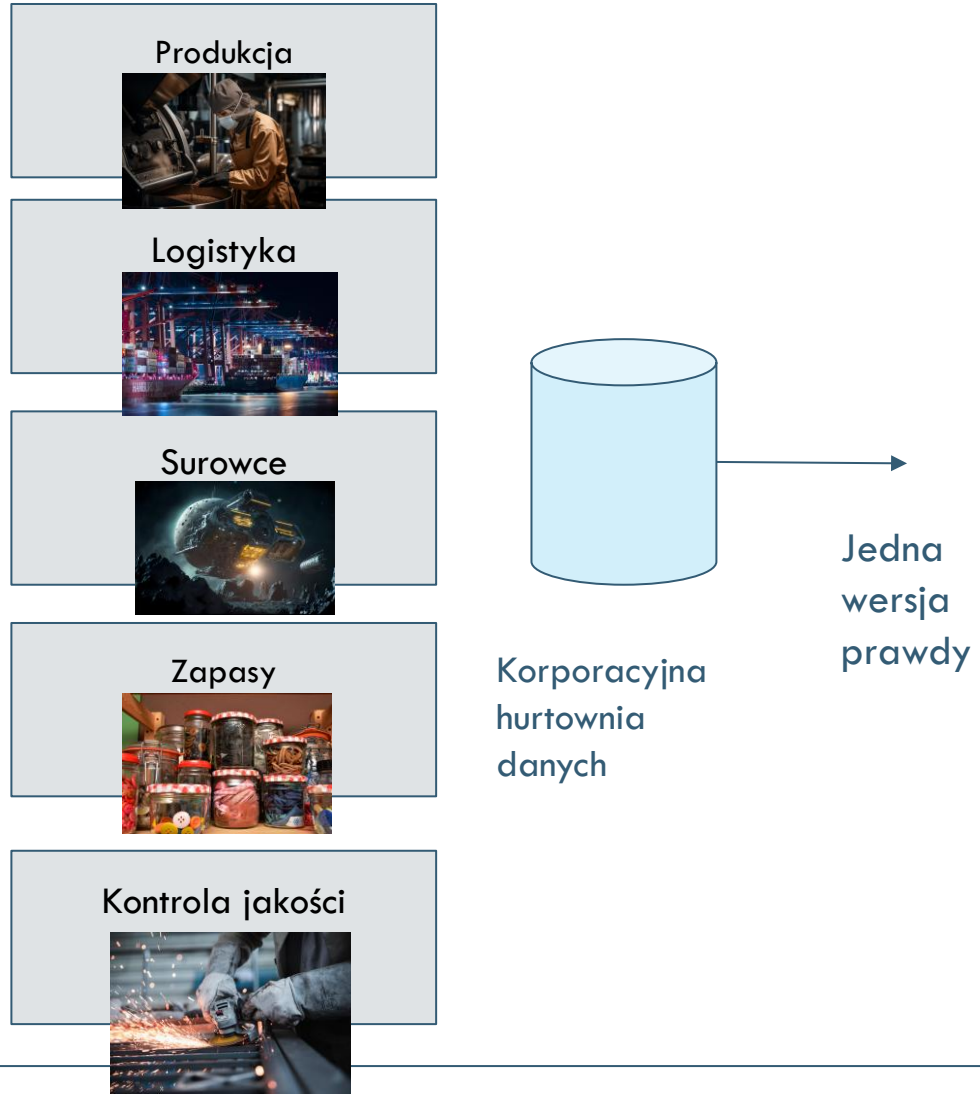

ROZDZIAŁ 1- RELACYJNA HURTOWNIA DANYCH

RELACYJNE HURTOWNIE DANYCH (DWH)

Definicja: Centralne repozytorium danych zintegrowanych z wielu źródeł, zoptymalizowane pod kątem analizy i raportowania.

Twórcy potęgi: Bill Inmon ("Single source of truth") oraz Ralph Kimball (podejście wymiarowe).

Główny cel: Wsparcie decyzji biznesowych (Business Intelligence).

Architektura hurtowni danych

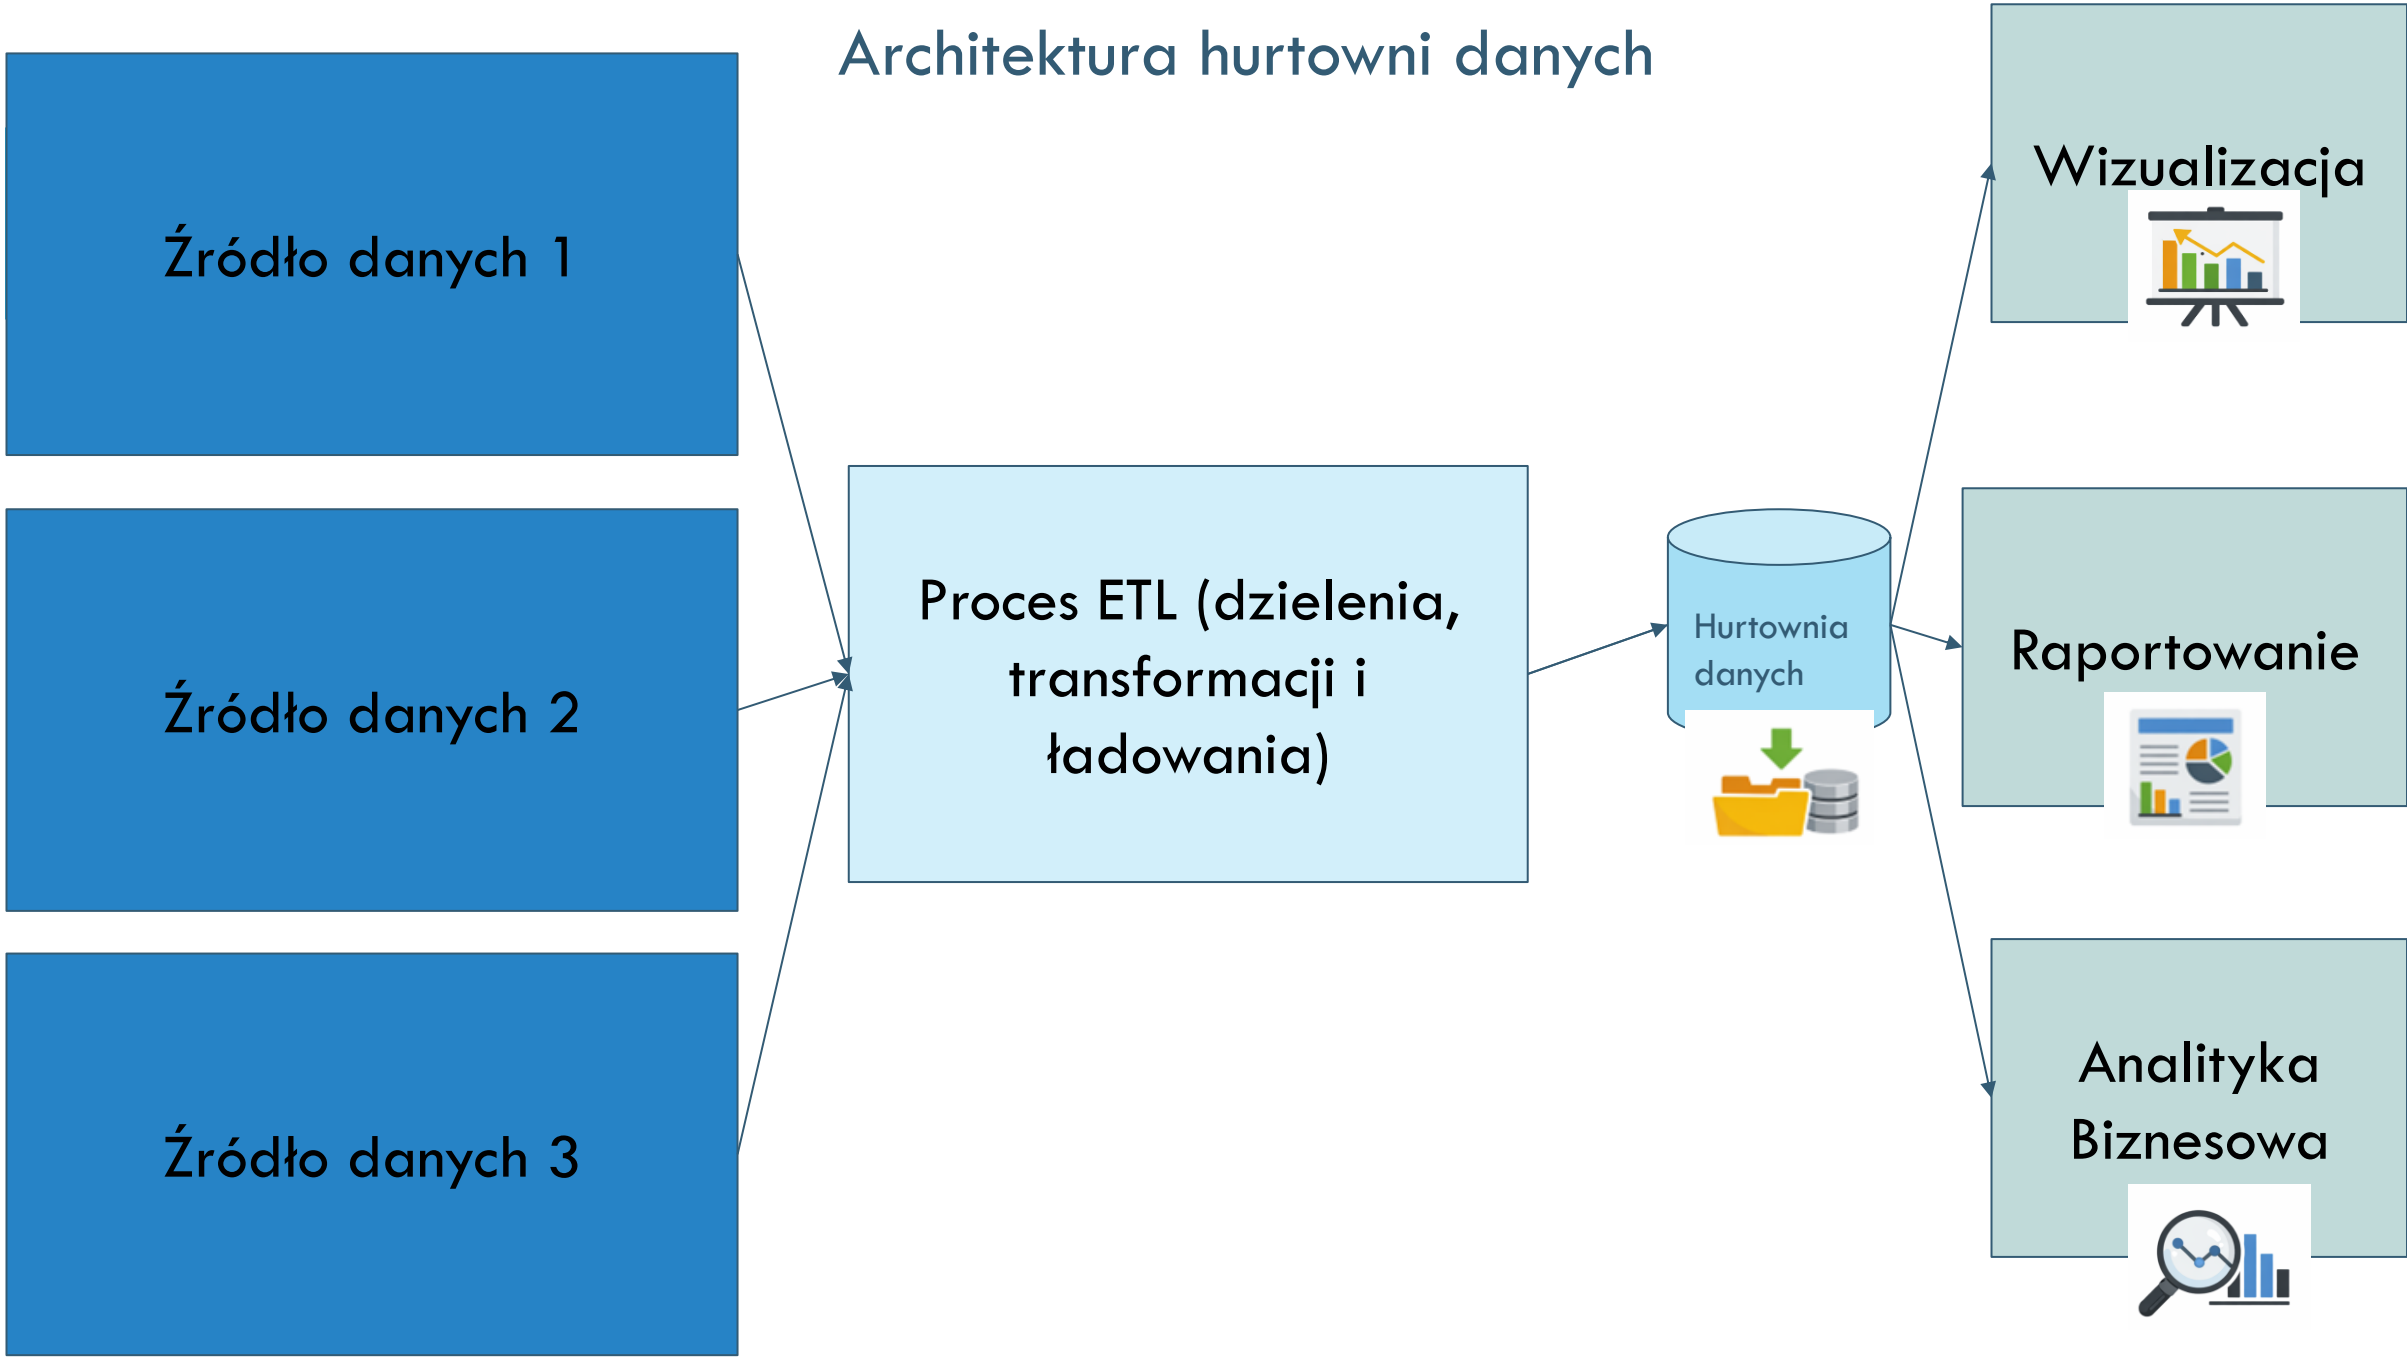

KLUCZOWA CECHA: SCHEMA-ON-WRITE

- **Zasada działania:** Struktura danych (tabel) musi być zdefiniowana *przed* załadowaniem danych.
- **Zalety:**
- Wysoka jakość i spójność (nie wgrasz "śmieci").
- Bardzo szybkie zapytania SQL.
- **Wady:** Mała elastyczność – każda zmiana w biznesie wymaga przebudowania procesu ETL.

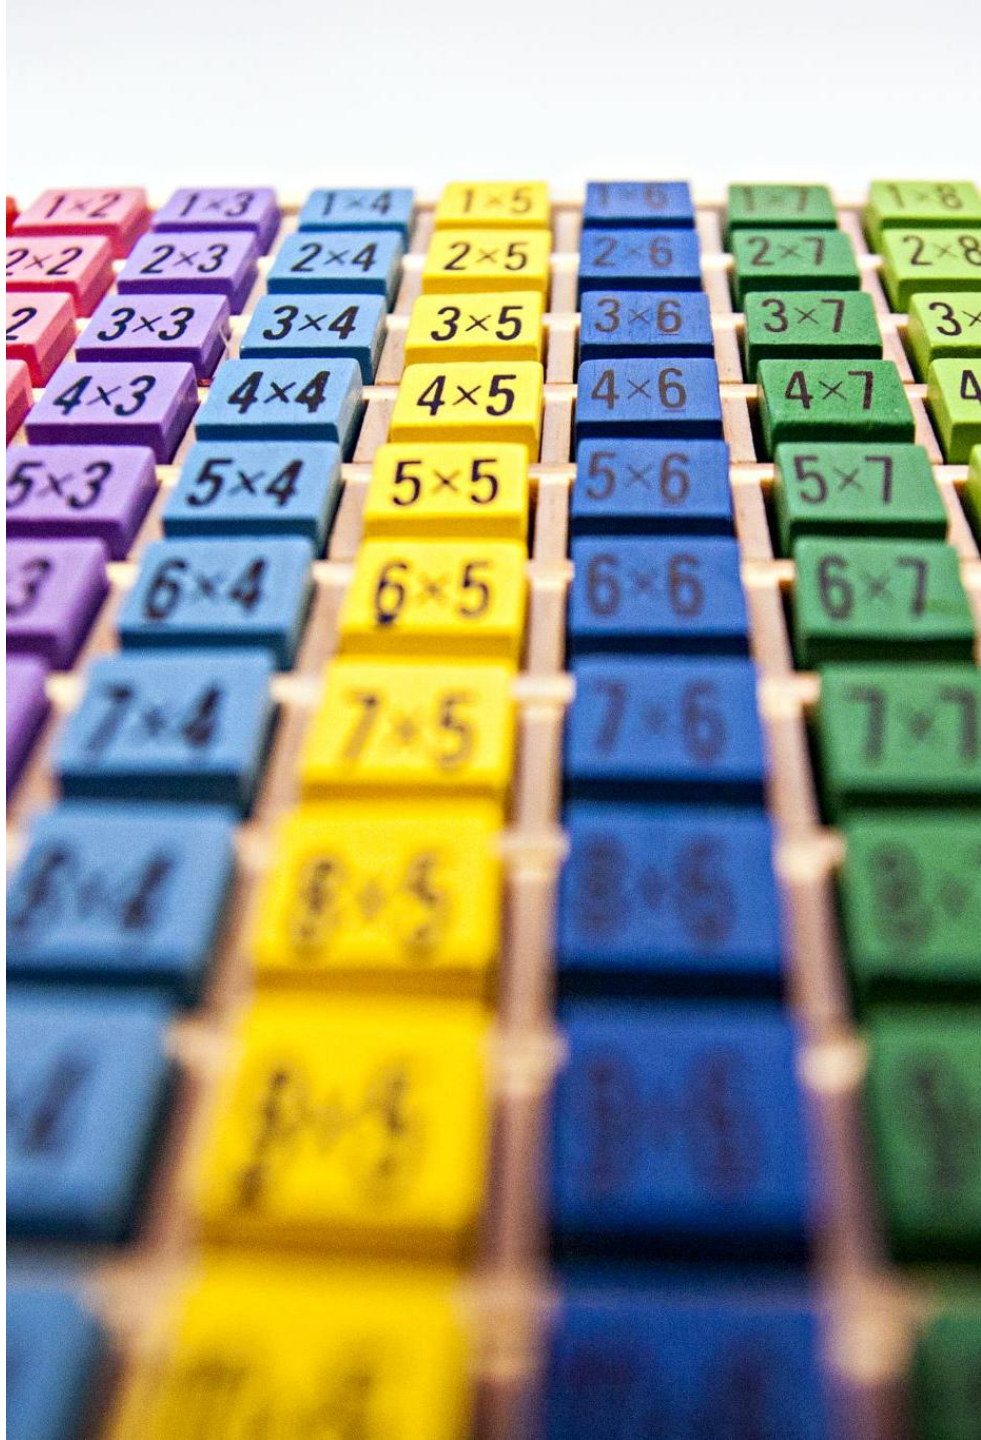

STANDARD ACID W HURTOWNIACH

- **Atomicity (Atomowość):** Transakcja wykonuje się w całości lub wcale.
- **Consistency (Spójność):** Dane zawsze spełniają reguły walidacji.
- **Isolation (Izolacja):** Jednoczesne operacje nie wpływają na siebie.
- **Durability (Trwałość):** Raz zapisane dane są bezpieczne (nawet przy awarii).
- **Dlaczego to ważne?** Gwarantuje, że raport finansowy zawsze pokaże prawdę.

OGRANICZENIA TRADYCYJNYCH HURTOWNI

- **Wysoki koszt:** Skalowanie pionowe (kupowanie większych serwerów) jest bardzo drogie.
- **Sztywność:** Trudność w obsłudze danych niestrukturalnych (np. zdjęcia, posty z social media).
- **Opóźnienie (Latency):** Dane w hurtowni często są dostępne dopiero następnego dnia (ładowanie nocne).
- **Wniosek:** Potrzeba czegoś bardziej elastycznego doprowadziła do powstania Data Lake.

ROZDZIAŁ 2: JEZIORO DANYCH- DATA LAKE

DATA LAKE – JEZIORO DANYCH

Definicja: Wielkoskalowe repozytorium, które przechowuje ogromne ilości surowych danych w ich natywnym formacie.

Metafora: W przeciwieństwie do "butelkowanej wody" (hurtownia), jezioro jest zasilane strumieniami danych z wielu źródeł w sposób ciągły.

Główne hasło: "Zapisz teraz, analizuj później".

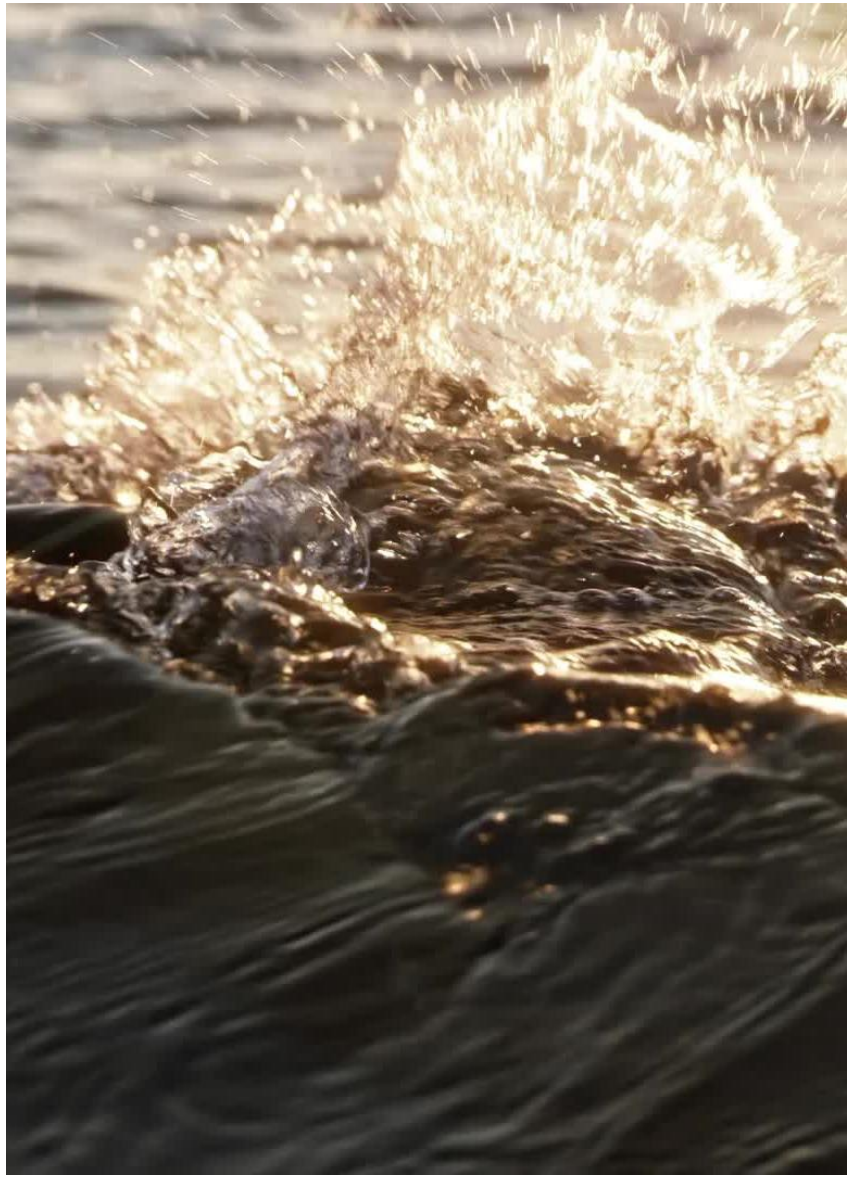

DLACZEGO POWSTAŁY JEZIORA DANYCH?

- **Eksplozja danych niestrukturalnych:** Tylko ok. 20% danych w firmach to tabele. Reszta to logi, obrazy, PDF-y i dane z czujników (IoT).
- **Ekonomia skali:** Koszt przechowywania 1 TB w Data Lake (np. na Amazon S3) jest ułamkiem kosztu w tradycyjnej bazie SQL.
- **Potrzeby Data Science:** Analitycy potrzebują dostępu do danych surowych, a nie tylko zagregowanych wyników.

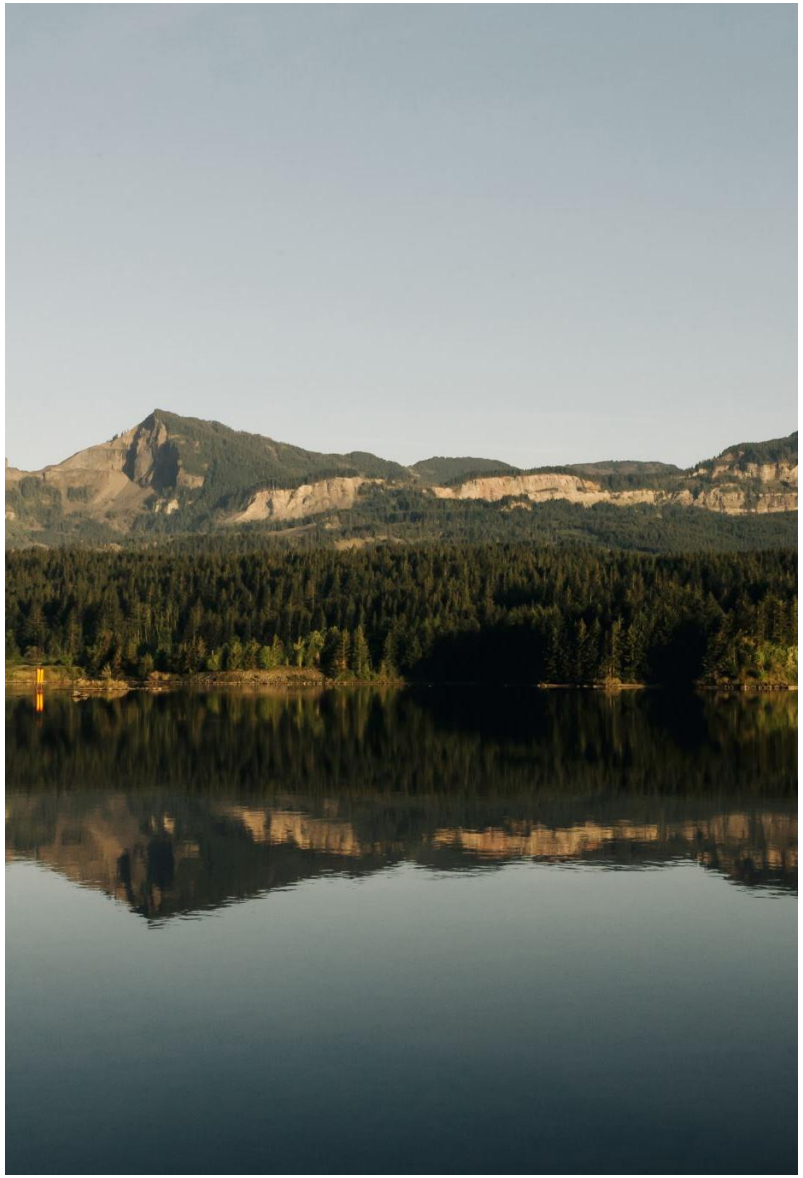

JEZIORO DANYCH-ARCHITEKTURA

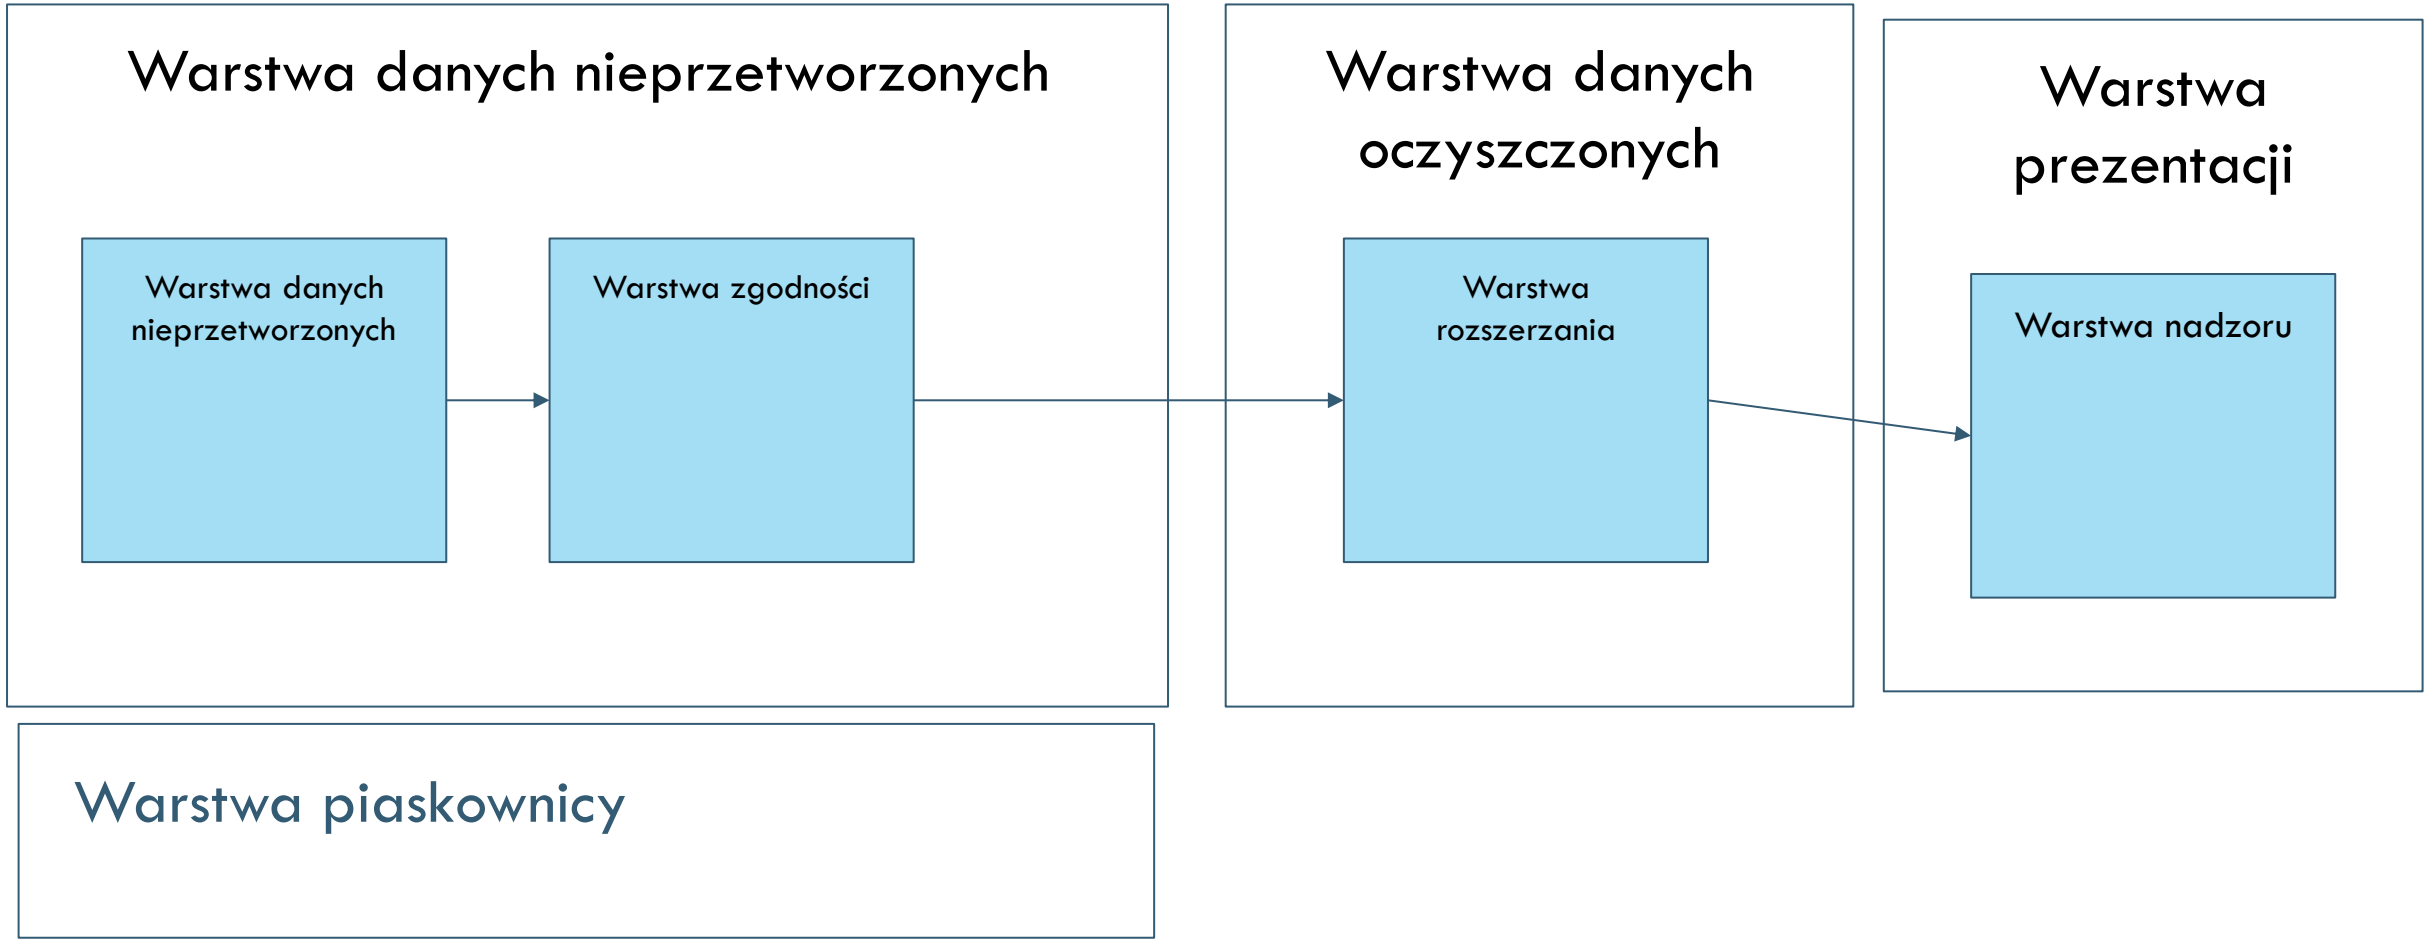

KLUCZOWA CECHA: SCHEMA-ON-READ

- **Zasada działania:** Dane są wrzucane do "jeziora" bez narzuconej struktury. Schemat (struktura) jest nakładany dopiero w momencie odczytu przez aplikację.
- **Korzyści:**
  - Błyskawiczne ładowanie danych (brak ciężkich procesów ETL).
  - Elastyczność: Te same dane mogą być interpretowane na różne sposoby przez różne zespoły.

FORMATY PRZECHOWYWANIA W DATA LAKE

- **Formaty tekstowe:** CSV, JSON, XML (łatwe do odczytu, ale mało wydajne).
- **Formaty binarne (zorientowane kolumnowo): * Apache Parquet:** Standard w Big Data, świetna kompresja i szybkość odczytu.
- **Apache Avro:** Idealny do danych strumieniowych.
- **Zaleta:** Formaty te pozwalają na odczyt tylko wybranych kolumn, co drastycznie przyspiesza analizę.

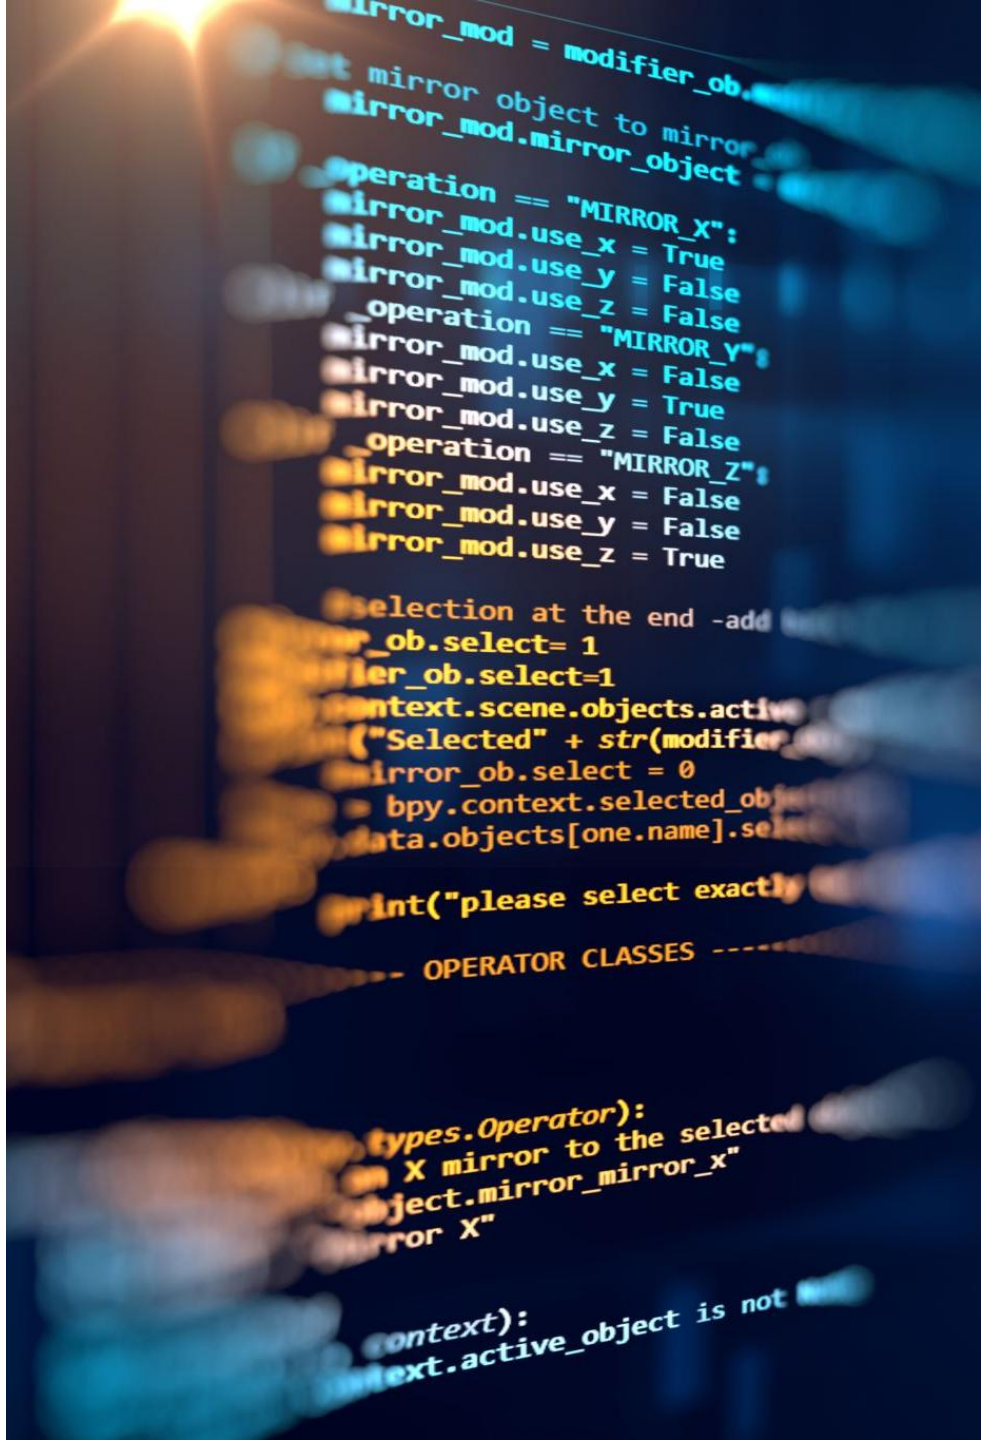

ARCHITEKTURA DATA LAKE W PRAKTYCE

Ingestia: Narzędzia takie jak Apache Kafka czy Azure Data Factory przesyłają dane.

Storage: Rozproszone systemy plików (HDFS) lub chmurowy storage obiektowy (S3, ADLS).

Przetwarzanie: Silniki typu Apache Spark, Presto czy Trino, które "pływają" po jeziorze, by wyciągnąć wnioski.

STRUKTURA KATALOGÓW W DWÓCH STREFACH JEZIORA DANYCH

Strefa danych nieprzetworzonych

Tematyka
-źródło danych
– Obiekt
—-Załadowane dane
—---Pliki

Sprzedaż
–Handlowcy
—--DaneKontaktoweKlientów
—-----2016
—---------12
—----------KontaktKlient_2016_12_01.txt

Strefa danych oczyszczonych
Przeznaczenie
– Typ
—-Data zapisu stanu danych
—------Pliki

Analiza trendów sprzedażowych
—Podsumowanie
—----2016_12_01
—-------TrendSprzedazowy_2016_12_txt

NAJWIĘKSZE ZAGROŻENIE: DATA SWAMP (BAGNO DANYCH)

- **Kiedy jezioro staje się bagnem?**
- Brak metadanych (nie wiadomo, co jest w plikach).
- Brak kontroli wersji i brak dbałości o jakość.
- Brak zarządzania uprawnieniami (Security).
- **Efekt:** Dane są przechowywane, ale nikt nie potrafi ich użyć do podjęcia decyzji.

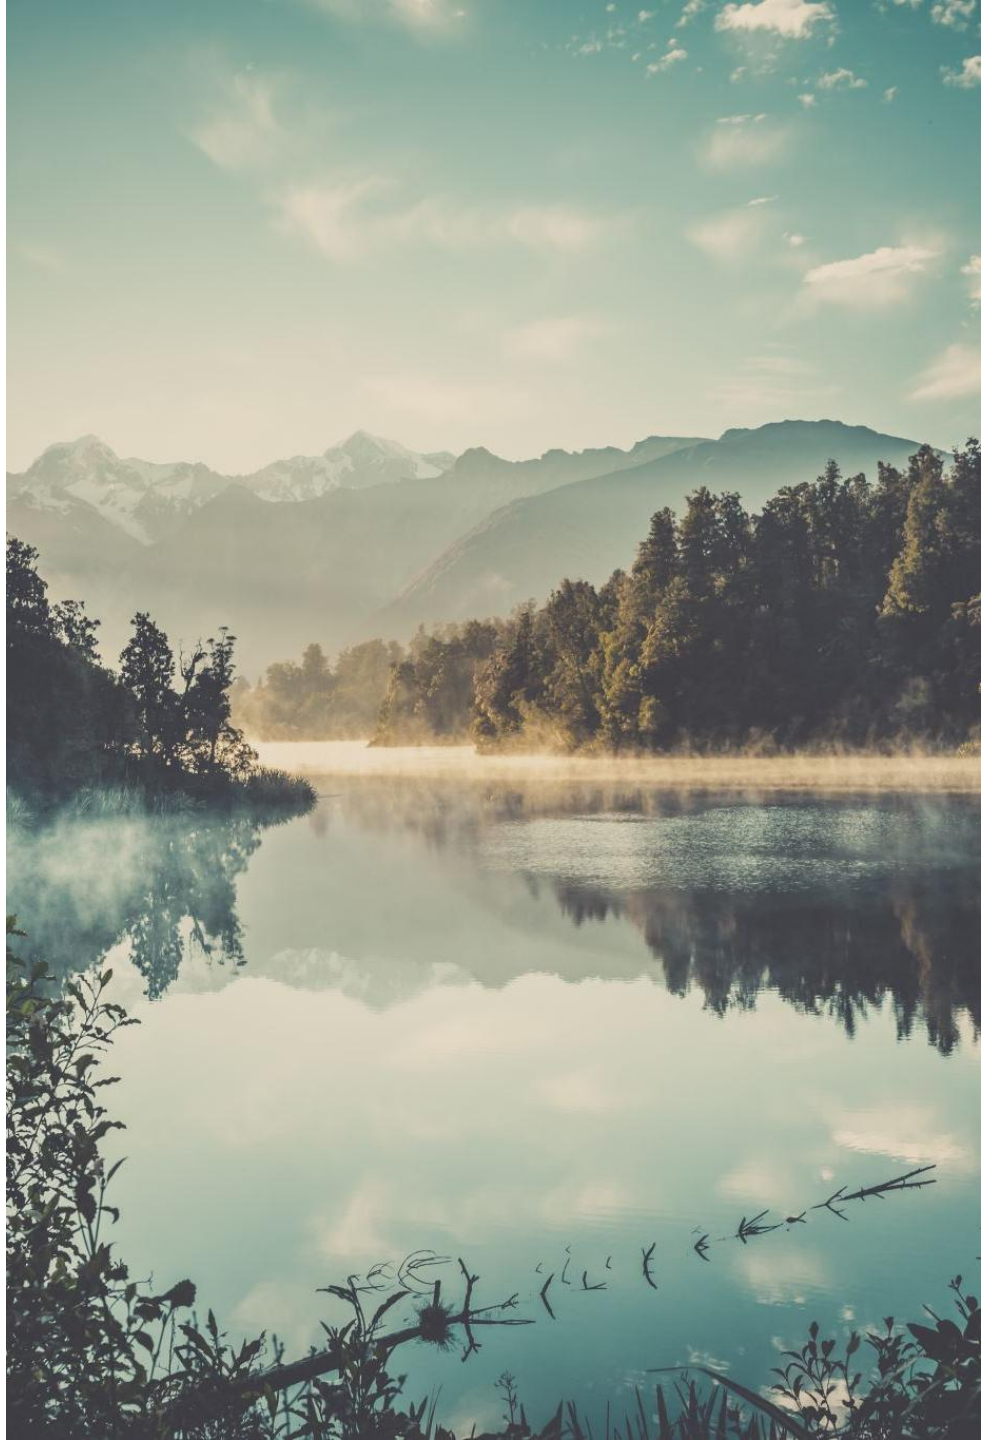

DWH VS DATA LAKE – PORÓWNANIE

Cecha	Hurtownia Danych (DWH)	Jezioro Danych (Data Lake)
Dane	Strukturalne	Wszystkie (surowe)
Schemat	Przy zapisie (Schema-on-write)	Przy odczycie (Schema-on-read)
Użytkownicy	Analitycy biznesowi (BI)	Data Scientists, Inżynierowie
Koszt	Wysoki	Niski

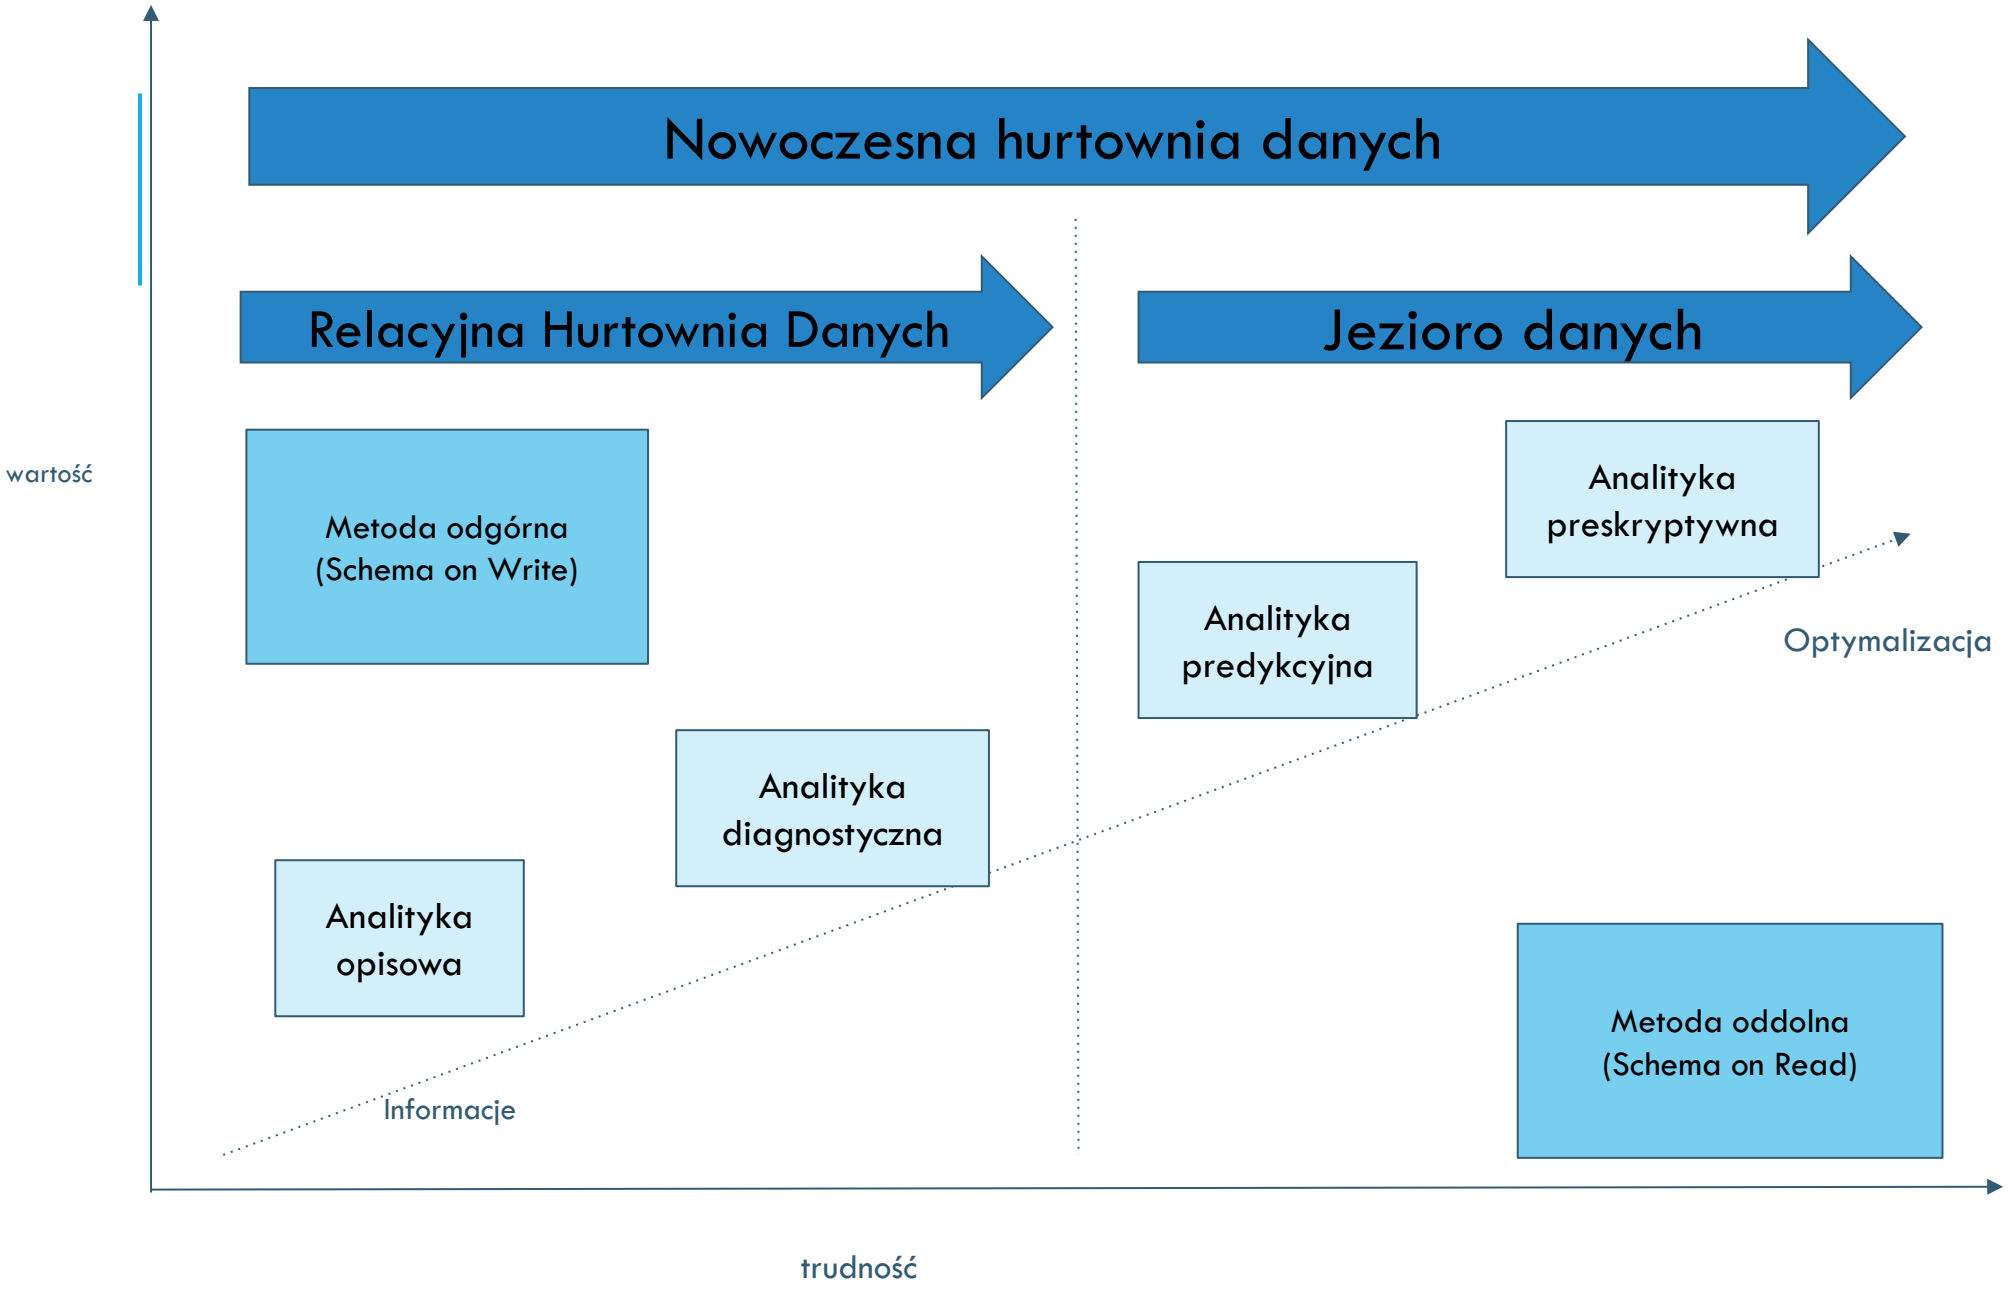
Nowoczesna hurtownia danych
Relacyjna Hurtownia Danych
Jezioro danych
wartość
Metoda odgórna
(Schema on Write)
Analityka
preskryptywna
Analityka
predykcyjna
Optymalizacja
Analityka
diagnostyczna
Analityka
opisowa
Metoda oddolna
(Schema on Read)
Informacje
trudność

ROZDZIAŁ 3: NOWOCZESNA HURTOWNIA DANYCH W CHMURZE

NOWOCZESNA HURTOWNIA DANYCH W CHMURZE

Przełom: Przeniesienie hurtowni z własnych serwerowni (on-premise) do chmury obliczeniowej.

Kluczowi gracze: Snowflake, Google BigQuery, Amazon Redshift.

Główna zmiana: Odejście od ograniczeń sprzętowych na rzecz nieskończonej skalowalności chmury.

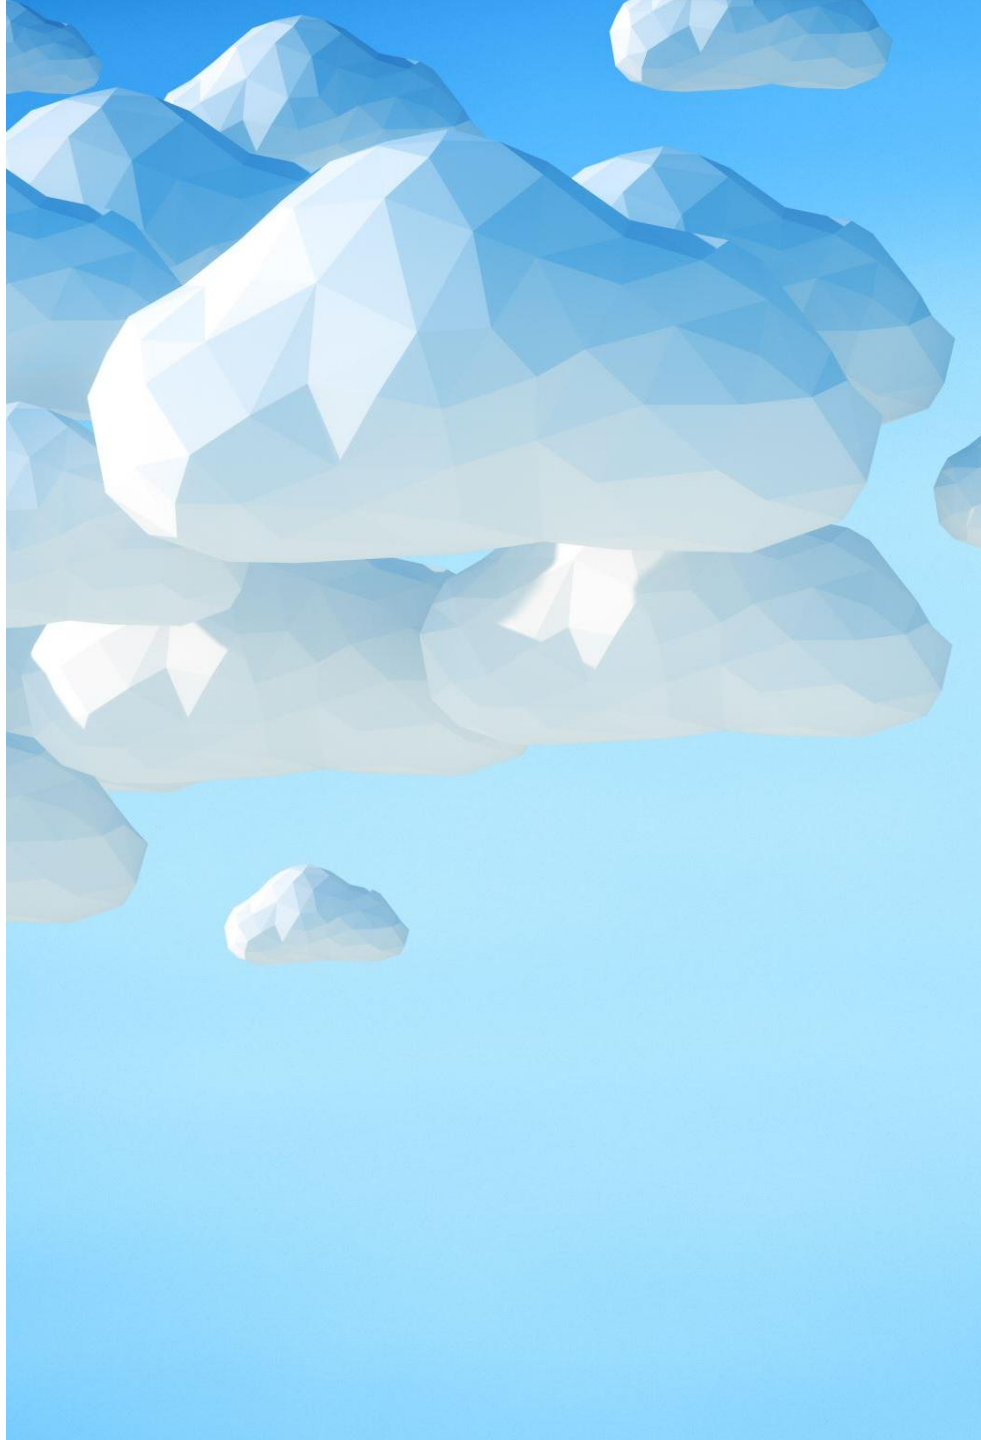

SEPARACJA ZASOBÓW (COMPUTE VS STORAGE)

Tradycyjnie: Aby mieć więcej miejsca, musiałeś dokupić serwer z procesorami (płacenie za moc, której nie używasz).

Nowocześnie:

- Storage: Płacisz grosze za przechowywanie petabajtów.

- Compute: Uruchamiasz "silnik" obliczeniowy tylko na czas trwania zapytania SQL.

Wynik: Ogromna oszczędność kosztów i elastyczność.

ZMIANA PARADYGMATU: Z ETL NA ELT

- **Extract, Load, Transform:**

1. Pobierz dane.
2. Załaduj je w formie surowej do chmurowej hurtowni.
3. Wykorzystaj potężną moc obliczeniową chmury, by przetworzyć dane na miejscu za pomocą SQL.

- **Dlaczego to lepsze?** Bo nowoczesne hurtownie (np. BigQuery) radzą sobie z transformacją miliardów wierszy w sekundy.

SKALOWALNOŚĆ HORYZONTALNA I SERVERLESS

- **Skalowanie pionowe vs poziome:** Zamiast jednego wielkiego serwera, używamy setek małych maszyn pracujących równolegle.

- **Model Serverless:** Użytkownik nie zarządza infrastrukturą. System automatycznie przydziela moc obliczeniową w zależności od skomplikowania zapytania SQL.

- **Zaleta:** Brak konieczności planowania wydajności "na zapas".

OBSŁUGA DANYCH PÓŁSTRUKTURALNYCH (SEMI-STRUCTURED DATA)

Nowoczesne SQL: Możliwość natywnego odpytywania plików JSON, Parquet czy XML bez ich wcześniejszego rozbijania na tabele.

Typ danych VARIANT/JSON: Hurtownie takie jak Snowflake pozwalają na przechowywanie schematów dynamicznych.

Zastosowanie: Analityka danych z aplikacji mobilnych i systemów webowych w czasie rzeczywistym.

DATA SHARING – WSPÓŁDZIELENIE DANYCH BEZ KOPIOWANIA

- **Tradycyjnie:** Aby przekazać dane partnerowi, trzeba było wysłać plik FTP lub stworzyć kopię bazy.
- **Nowocześnie:** Udostępnianie "widoku" na żywo. Partner widzi dane w Twojej hurtowni (z zachowaniem uprawnień) bez ich fizycznego przesyłania.
- **Korzyść:** Jedno źródło prawdy i zerowe koszty transferu danych (egress fees).

WĘDRÓWKA DANYCH W NOWOCZESNEJ HURTOWNI DANYCH

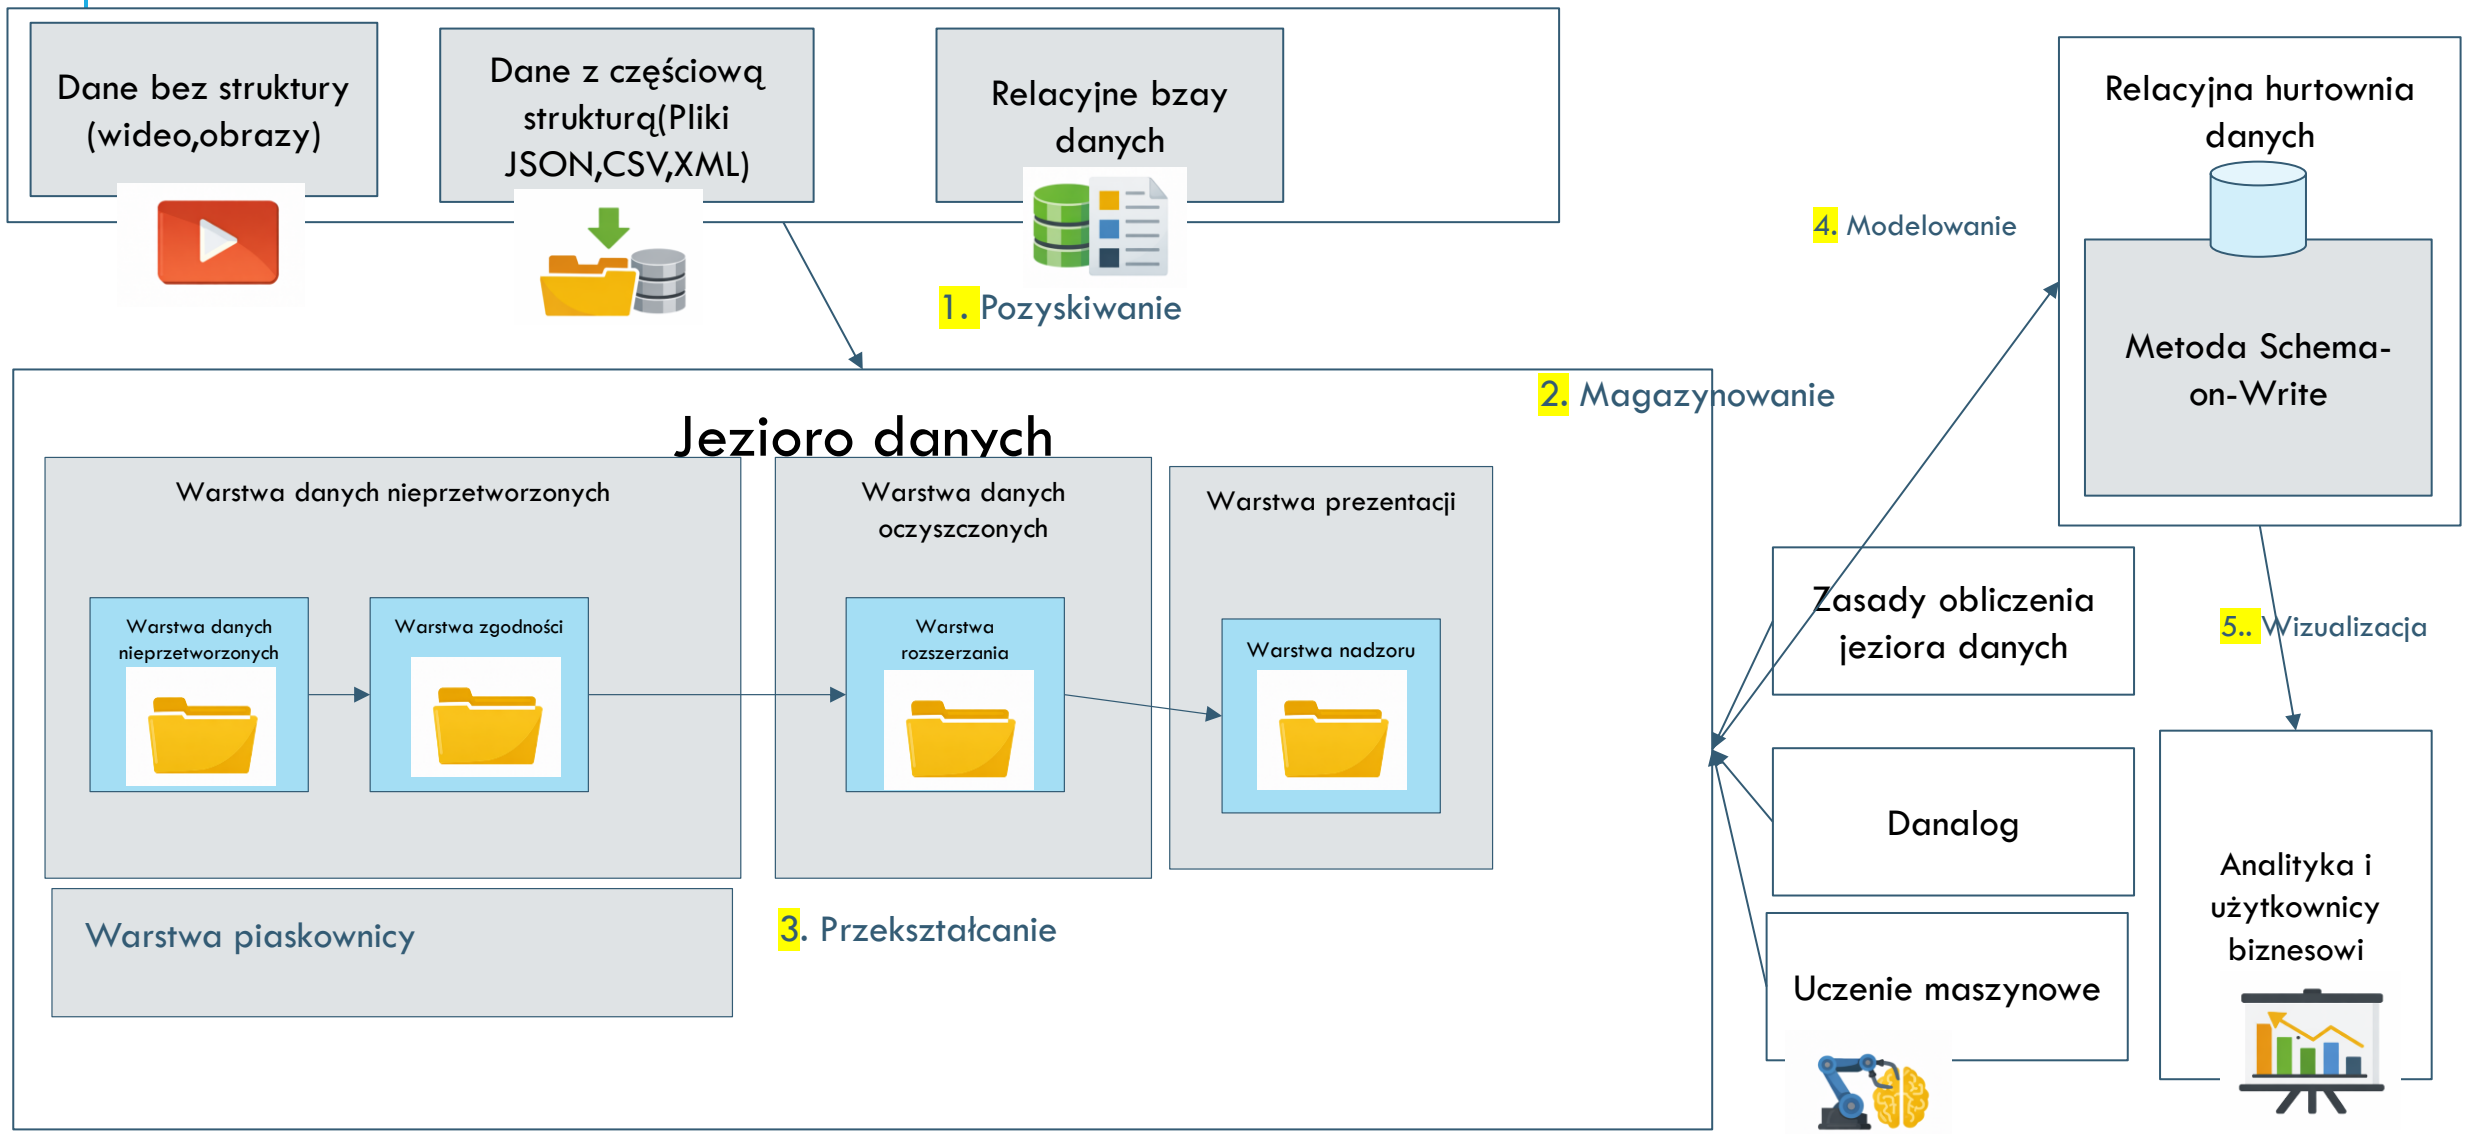

BEZPIECZEŃSTWO I GOVERNANCE W CHMURZE

- **Maskowanie danych (Data Masking):** Ukrywanie wrażliwych danych (np. PESEL) przed nieuprawnionymi użytkownikami.
- **Role-Based Access Control (RBAC):** Precyzyjne zarządzanie dostępem na poziomie wierszy i kolumn.
- **Audyt:** Pełna historia tego, kto, kiedy i jakie zapytanie wykonał (wymóg RODO/GDPR).

ROZDZIAŁ 4: DATA LAKE HOUSE

DATA LAKEHOUSE – NOWY PARADYGMAT

Problem dwóch systemów: Firmy utrzymywały DWH (dla BI) i Data Lake (dla ML). To generowało koszty i niespójność danych.

Data Lakehouse: Nowa architektura, która łączy wydajność i strukturę hurtowni z elastycznością i niskim kosztem jeziora danych.

Kluczowa idea: SQL bezpośrednio na tanim storage'u obiektowym.

FUNDAMENTY LAKEHOUSE – OTWARTOŚĆ I TRANSAKCYJNOŚĆ

- **Otwarte formaty:** Dane nie są zamknięte w formacie dostawcy (jak w Oracle/SQL Server), lecz trzymane w otwartych formatach (Parquet/Iceberg).
- **Warstwa metadanych:** Kluczowy element, który nadaje strukturę plikom leżącym w jeziorze.
- **Niezależność:** Możesz zmienić narzędzie analityczne bez konieczności migracji samych danych.

TRANSAKCJE ACID NA JEZIORZE DANYCH

- **Delta Lake / Iceberg / Hudi:** Technologie, które umożliwiają operacje UPDATE, DELETE i MERGE na plikach w Data Lake.
- **Problem "Concurrent Writes":** Lakehouse rozwiązuje konflikt, gdy dwie osoby próbują zapisać dane w tym samym czasie.
- **Zaleta:** Koniec z uszkodzonymi danymi w jeziorze po przerwanym procesie ładowania.

ARCHITEKTURA DELTA LAKE

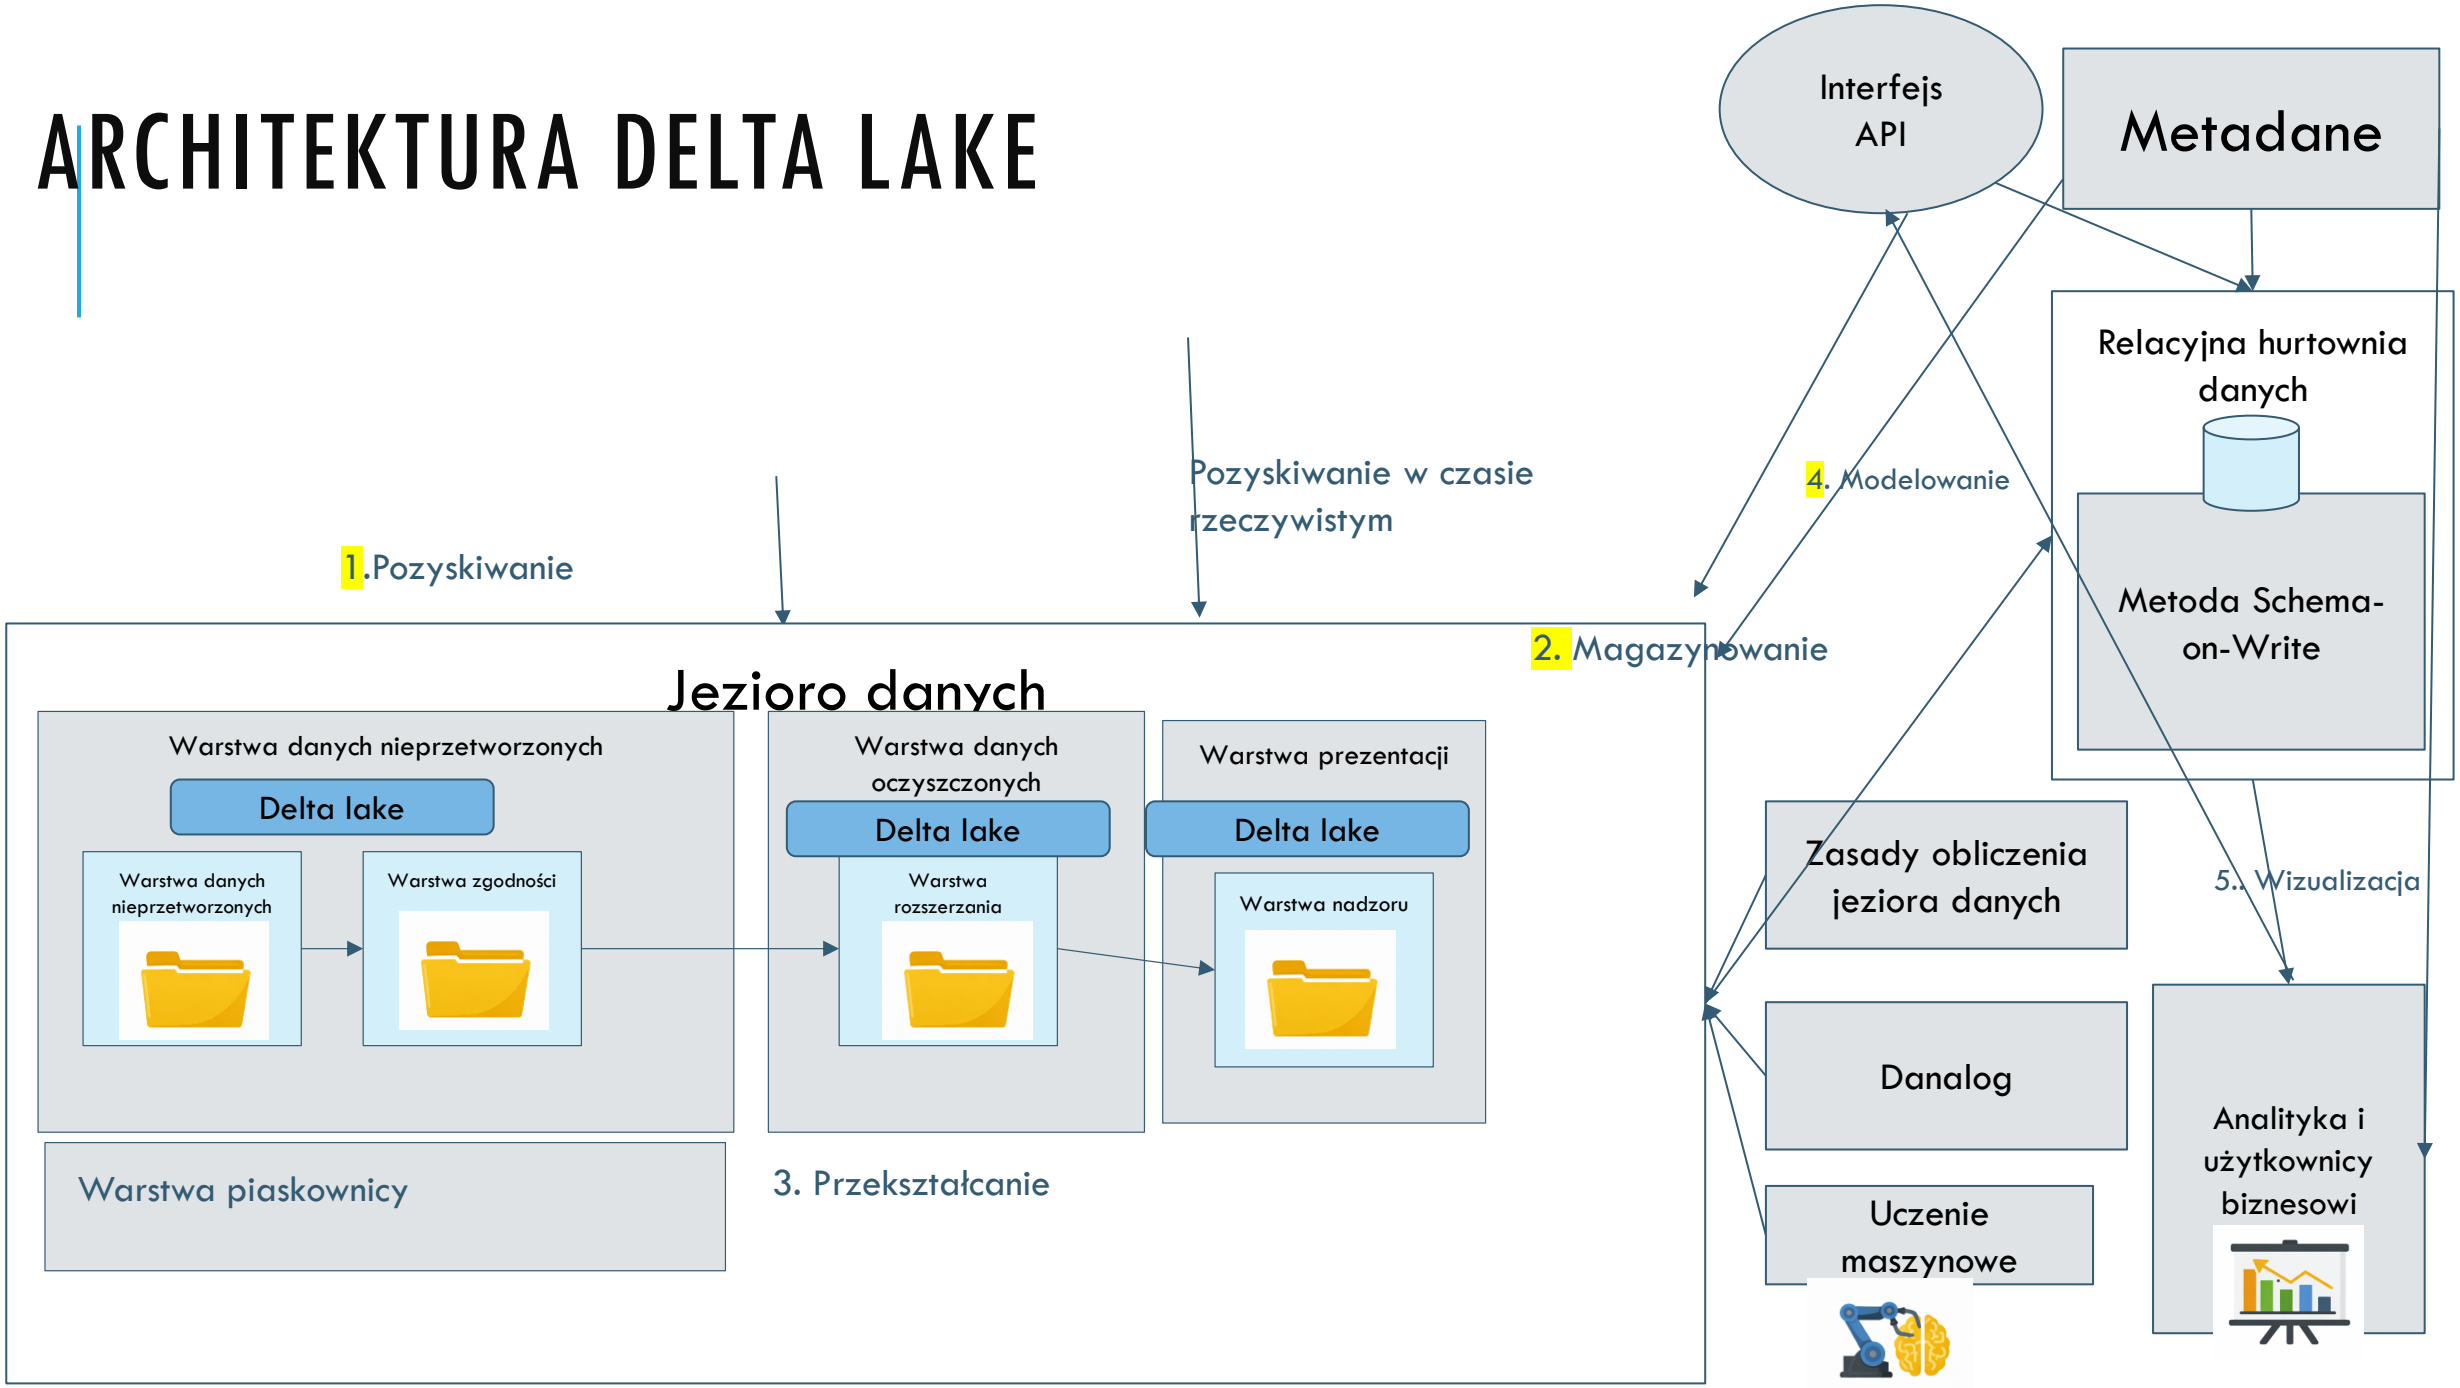

ARCHITEKTURA MEDALIONOWA (MEDALLION ARCHITECTURE)

1

Warstwa Bronze (Raw): Dane surowe, prosto ze źródeł (często historia wszystkiego).

2

Warstwa Silver (Cleaned): Dane oczyszczone, przefiltrowane, ujednolicone (gotowe do analityki).

3

Warstwa Gold (Curated): Agregaty biznesowe, dane gotowe do zasilenia dashboardów i raportów.

TIME TRAVEL – PODRÓŻ W CZASIE W DANYCH

- **Definicja:** Możliwość odpytania stanu danych z dowolnego momentu w przeszłości.
- **Jak to działa?** System przechowuje logi zmian (Transaction Log).
- **Zastosowania:**
- Odtwarzanie danych po błędzie ludzkim.
- Audyt zmian.
- Odtwarzalność modeli Machine Learning (trenowanie na danych z konkretnego dnia).

WYDAJNOŚĆ W LAKEHOUSE – JAK TO MOŻLIWE?

- **Optymalizacja układu plików:** Grupowanie danych (Clustering) i indeksowanie.
- **Caching:** Często używane dane są kopiowane z wolniejszego S3/Azure Blob do szybkiej pamięci RAM procesora.
- **Statystyki plików:** Pomijanie niepotrzebnych plików podczas skanowania (Data Skipping)

ZASTOSOWANIA LAKEHOUSE – JEDNO ŹRÓDŁO PRAWDY

Business Intelligence (BI): Raportowanie na danych z warstwy Gold przy użyciu standardowego SQL.

Data Science & ML: Bezpośredni dostęp do danych surowych (warstwa Bronze/Silver) dla modeli predykcyjnych.

Streaming & Real-time: Przetwarzanie danych w czasie rzeczywistym i natychmiastowa widoczność w tabelach.

Korzyść: Brak konieczności kopiowania danych między systemami.

LIDERZY RYNKU I TECHNOLOGIE WSPIERAJĄCE

Databricks: Pionier koncepcji Lakehouse, twórca Delta Lake.

Microsoft Fabric: Zintegrowana platforma łącząca jezioro (OneLake) z analityką.

Apache Iceberg: Otwarty format tabelaryczny wspierany przez Google, AWS i Snowflake.

Snowflake (Unistore): Ewolucja hurtowni w stronę obsługi transakcji i jeziora danych.

ROZDZIAŁ 6: PORÓWNANIE I WYBÓR STRATEGII

PORÓWNANIE I WYBÓR STRATEGII

Kiedy zostać przy klasycznym DWH? Małe/średnie zbiory danych, wyłącznie dane strukturalne, wysokie wymagania co do szybkości prostych raportów.

Kiedy wybrać Data Lake? Archiwizacja ogromnych ilości danych, bardzo niski budżet, czyste Data Science bez potrzeb raportowych.

Kiedy przejść na Data Lakehouse? Skala Big Data, potrzeba zaawansowanej analityki (AI/ML) i raportowania BI w jednym miejscu.

Tabela porównawcza – Podsumowanie technologii

Cecha	Relacyjne DWH	Data Lake	Data Lakehouse
Format danych	Zamknięty (Proprietary)	Otwarty (Pliki)	Otwarty (Tabelaryczny)
ACID	Tak (Pełne)	Nie	Tak
Koszt Storage	Wysoki	Bardzo niski	Niski
Wydajność SQL	Bardzo wysoka	Niska	Wysoka
Obsługa AI/ML	Słaba	Bardzo dobra	Bardzo dobra

TRENDY NA ROK 2026 I PRZYSZŁOŚĆ

Data Mesh: Decentralizacja zarządzania danymi – dane jako produkt (Data as a Product).

AI-driven Storage: Automatyczna optymalizacja indeksów i partycji przez sztuczną inteligencję.

Zero-Copy Integration: Integracja różnych chmur bez fizycznego przesyłania bajtów.

Suwerenność danych: Przechowywanie danych zgodnie z lokalnymi regulacjami (Gaia-X, polskie chmury krajowe).

FINOPS – ZARZĄDZANIE KOSZTAMI PRZECHOWYWANIA

Pułapka chmury: Łatwość skalowania może prowadzić do niekontrolowanych kosztów.

Strategie oszczędności:

- Automatyczne usypianie klastrów obliczeniowych.
- Tiering: Przenoszenie starych danych na "Cold Storage" (np. S3 Glacier).
- Monitorowanie zapytań o wysokim koszcie.

PODSUMOWANIE KLUCZOWYCH WNIOSKÓW

- Ewolucja dąży do **unifikacji**: zacierają się granice między bazą danych a systemem plików.
- **Otwartość formatów** (Delta/Iceberg) staje się standardem rynkowym.
- Wybór technologii musi wynikać z **potrzeb biznesowych**, a nie z mody na konkretne narzędzie.
- Nowoczesna architektura musi być **elastyczna** (gotowa na zmiany formatów i skali).

BIBLIOGRAFIA I ŹRÓDŁA

Armbrust M., et al. (2021). "Lakehouse: A New Generation of Open Platforms".

Inmon W.H. (2020). "The Data Lakehouse".

Fowler M. (2020). "Data Mesh Principles and Logical Architecture".

Raporty Gartnera: "Magic Quadrant for Cloud DBMS" (2024-2025).

Dokumentacja techniczna: *Databricks Delta Lake*, *Apache Iceberg Project*, *Snowflake Architecture Whitepapers*.

PYTANIA ???